

Objetivos de la sesión

Introducir el concepto de reducción de dimensionalidad

Profundizar en los conceptos básicos de ML

Introducir el uso de PCA

Propiciar la interacción entre estudiantes y profesor

Problema

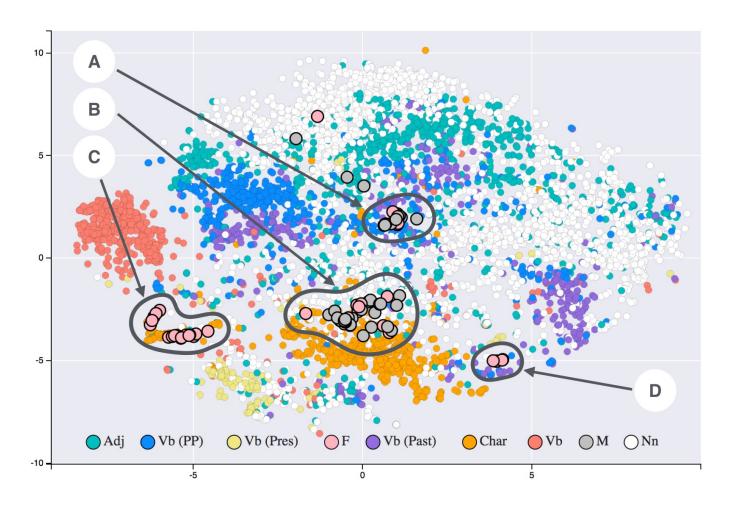
- Análisis de datos multivariados es importante
- Espacios con más de 3 dimensiones son difíciles de visualizar

• Se busca representar los datos de una manera que facilite el análisis

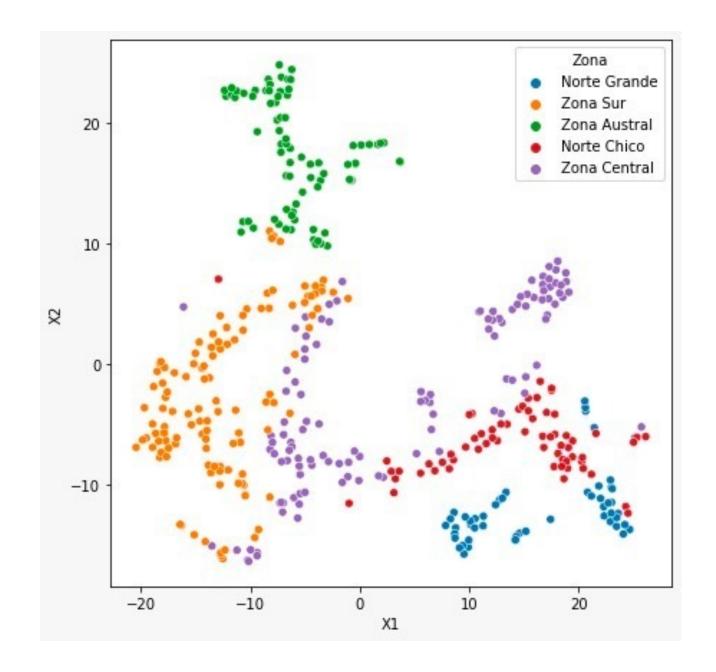
Beneficios

- Se reduce la carga computacional en las siguientes etapas
- Podría reducirse el ruido
- Proyectar los datos en un espacio de dimension pequeña es útil para visualizar los datos

- t-distributed stochastic neighbor embedding
- 2D o 3D
- Primero calcula una distribución de probabilidad para pares de objetos en la dimensión original, donde objetos similares (distancia euclidiana) tienen alta probabilidad y objetos diferentes tienen baja probabilidad
- Luego genera una nueva distribución en los pares de objetos de baja dimensión (2D o 3D) y minimiza la diferencia entre ambas distribuciones.



https://en.wikipedia.org/wiki/T-distributed_stochastic_neighbor_embedding



```
tSNE =
                                                          pd.DataFrame(TSNE(n components=2).fit transform(X),
                                                          columns = ['tSNE1', 'tSNE2'])

    import pandas as pd

    from sklearn.preprocessing import StandardScaler

                                                          # add the target

    from sklearn.decomposition import PCA

                                                         tSNE['target'] = y
• from sklearn.manifold import TSNE
• import seaborn as sns
                                                          sns.scatterplot(x='tSNE1', y='tSNE2', data=tSNE,
• import matplotlib.pyplot as plt
                                                          hue='target')

    %matplotlib inline

• url = "https://archive.ics.uci.edu/ml/machine-learning-databases/iris/iris.data"
df = pd.read_csv(url, names=['sepal length', 'sepal width', 'petal length', 'petal width', 'target'])
df.head()
• X = df.iloc[:,0:4]
• y = df.iloc[:,4]
X = StandardScaler().fit_transform(X)
```

the two components

Non-Negative Matrix Factorization (NMF)

• Similar a PCA, pero coeficientes son positivos

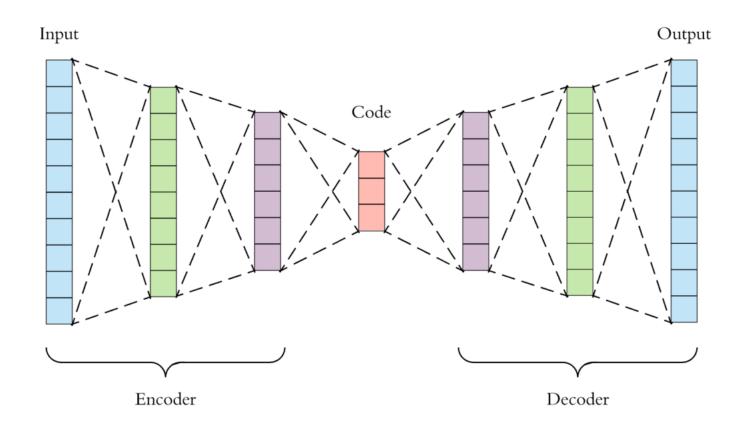
model.transform(televote_Rank)

• Útil cuando se requiere determinar factores aditivos

```
# Import NMF from sklearn.decomposition import NMF  \begin{array}{c} X = AB \\ \text{nxp} & \text{nxp} \end{array}  # Create an NMF instance: model model = NMF(n_components=2)  \begin{array}{c} X = AB \\ \text{model instance: model} \\ \text{model fit(televote_Rank)} \end{array}  # Transform the televote_Rank: nmf_features =  \begin{array}{c} X = AB \\ \text{nxp} & \text{nxp} \end{array}
```

https://predictivehacks.com/non-negative-matrix-factorization-for-dimensionality-reduction/

Autoencoders



https://predictivehacks.com/autoencoders-for-dimensionality-reduction/

Autoencoders

from tensorflow.keras.models import Sequential from tensorflow.keras.layers import Dense,Flatten,Reshape from tensorflow.keras.optimizers import SGD

from tensorflow.keras.datasets import mnist
(X_train, y_train), (X_test, y_test) = mnist.load_data()
X_train = X_train/255.0
X_test = X_test/255.0

```
encoded_2dim = encoder.predict(X_train)

# The 2D
AE = pd.DataFrame(encoded_2dim, columns = ['X1', 'X2'])
AE['target'] = y_train
sns.lmplot(x='X1', y='X2', data=AE, hue='target', fit_reg=False, size=10)
```

```
### Encoder
encoder = Sequential()
encoder.add(Flatten(input_shape=[28,28]))
encoder.add(Dense(400,activation="relu"))
encoder.add(Dense(200,activation="relu"))
encoder.add(Dense(100,activation="relu"))
encoder.add(Dense(50,activation="relu"))
encoder.add(Dense(2,activation="relu"))
### Decoder
decoder = Sequential()
decoder.add(Dense(50,input_shape=[2],activation='relu')
decoder.add(Dense(100,activation='relu'))
decoder.add(Dense(200,activation='relu'))
decoder.add(Dense(400,activation='relu'))
decoder.add(Dense(28 * 28, activation="relu"))
decoder.add(Reshape([28, 28]))
### Autoencoder
autoencoder = Sequential([encoder,decoder])
autoencoder.compile(loss="mse")
autoencoder.fit(X_train,X_train,epochs=50)
```

