



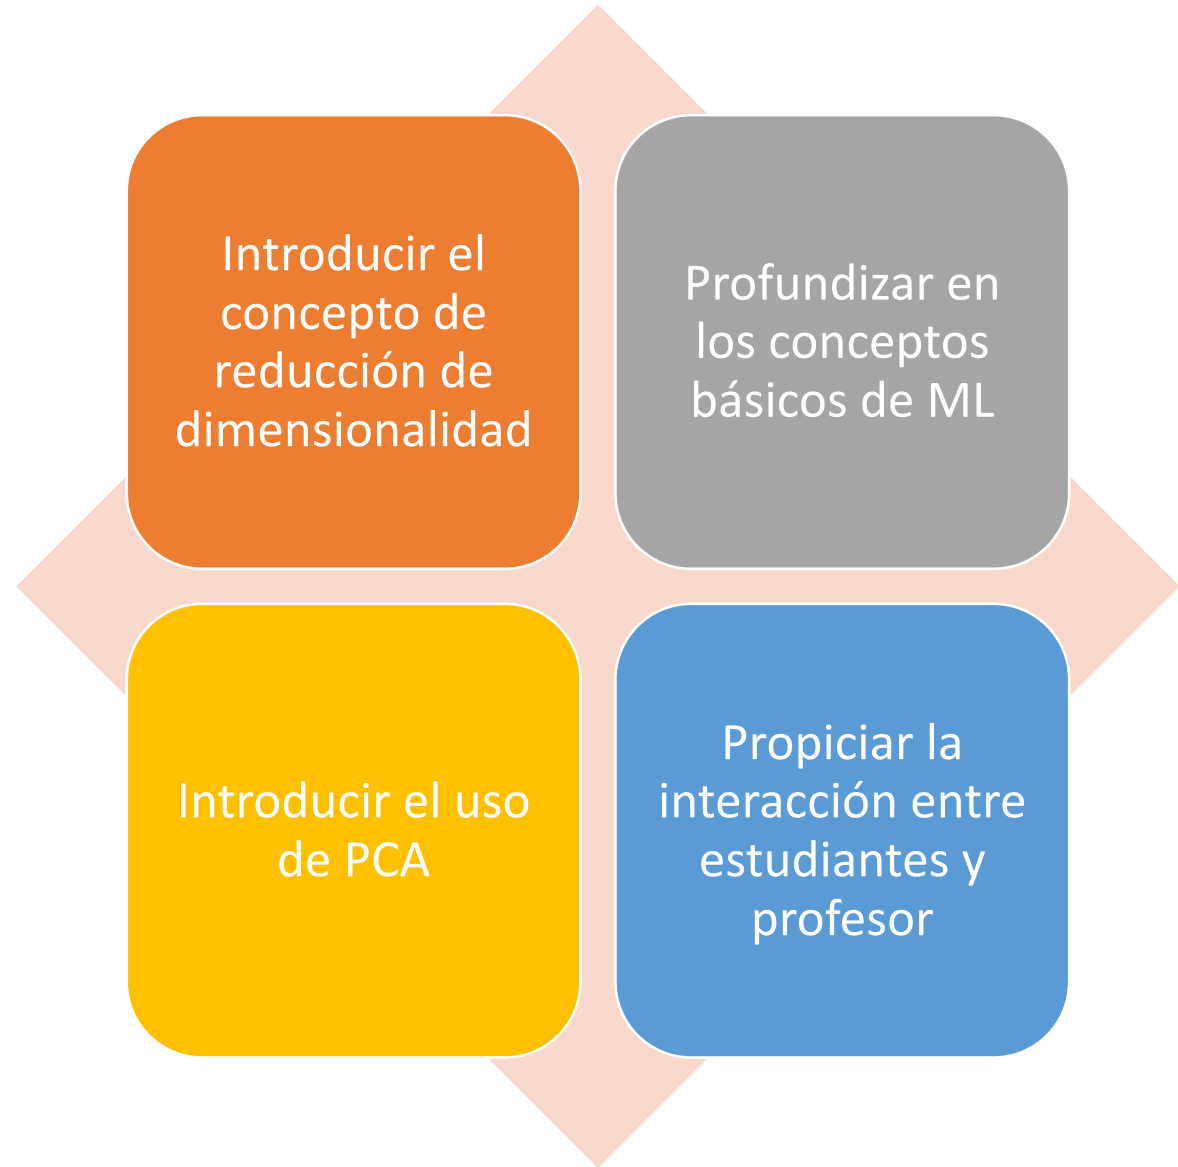
Inteligencia Artificial LFIS419

Clase 7: k-nearest neighbors y kmeans

Profesor: Jorge Arevalo (jorge.arevalo@uv.cl jab@meteo.uv.cl)

Martes 9 de mayo de 2023

Objetivos de la sesión



kNN

- Típicamente para clasificación, pero se puede usar para regresión
- 2 hiperparámetros k y distancia (métrica)
- Regularizar datos
- Requiere mucha memoria

$$\text{Minkowski Distance} = \left(\sum_{i=1}^n |x_i - y_i| \right)^{1/p}$$

p=2 -> euclidiana

P=1 -> Manhattan

kNN

```
from sklearn.neighbors import KNeighborsClassifier
model_name = 'K-Nearest Neighbor Classifier'
knnClassifier = KNeighborsClassifier(n_neighbors = 5, metric = 'minkowski', p=2)
knn_model = Pipeline(steps=[('preprocessor', preprocessorForFeatures), ('classifier' , knnClassifier)])
knn_model.fit(X_train, y_train)
y_pred = knn_model.predict(X_test)
```

kMeans

El algoritmo consta de tres pasos:

1. Inicialización: una vez escogido el número de grupos, k , se establecen k centroides en el espacio de los datos, por ejemplo, escogiéndolos aleatoriamente.

2. Asignación objetos a los centroides: cada objeto de los datos es asignado a su centroide más cercano.

3. Actualización centroides: se actualiza la posición del centroide de cada grupo tomando como nuevo centroide la posición del promedio de los objetos pertenecientes a dicho grupo.

Se repiten los pasos 2 y 3 hasta que los centroides no se mueven, o se mueven por debajo de una distancia umbral en cada paso.

```
In [1]: %matplotlib inline
```

Importamos las librerías y funciones necesarias


```
In [2]: import numpy as np
import matplotlib.pyplot as plt
```

Generamos datos aleatorios 2D para tres clusters y los representamos

```
In [3]: np.random.seed(7)


x1 = np.random.standard_normal((100,2))*0.6+np.ones((100,2))
x2 = np.random.standard_normal((100,2))*0.5-np.ones((100,2))
x3 = np.random.standard_normal((100,2))*0.4-2*np.ones((100,2))+5
X = np.concatenate((x1,x2,x3),axis=0)

plt.plot(X[:,0],X[:,1], 'k. ')
plt.show()
```





Inicio



Sorteamos los centroides





Iteración 1





Iteración 2




Iteración 3



Iteración 4




Reasignamos puntos a centroides




Iteración 5

Reubicamos centroides




Reasignamos puntos a centroides





Iteración 6



Reubicamos centroides



Iteración 7




Iteración 8



```
from sklearn.cluster import KMeans
```

```
n = 3  
k_means = KMeans(n_clusters=n)  
k_means.fit(X)
```

```
centroids = k_means.cluster_centers_  
etiquetas = k_means.labels_
```



```
plt.plot(X[etiquetas==0,0],X[etiquetas==0,1], 'r.', label='cluster 1')  
plt.plot(X[etiquetas==1,0],X[etiquetas==1,1], 'b.', label='cluster 2')  
plt.plot(X[etiquetas==2,0],X[etiquetas==2,1], 'g.', label='cluster 3')  
  
plt.plot(centroids[:,0],centroids[:,1], 'mo', markersize=8, label='centroids')  
  
plt.legend(loc='best')  
plt.show()
```